# Agrupamento de Documentos

Prof. Leandro Alvim, D.Sc.

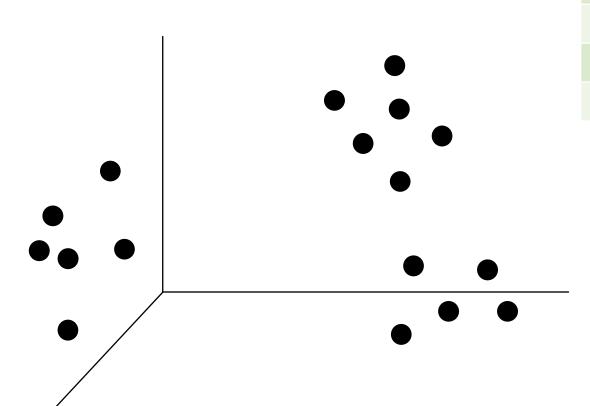
# Agenda

- Motivações
- O que é ?
- Metodologia
- Análise
- Ferramentas
- Considerações
- Exemplos de trabalhos acadêmicos

# Motivação

- Encontrar grupos
  - ► Padrões similares dentro do grupo
  - Padrões distintos entre grupos
- Mas por que ?
  - Novas descobertas para grandes volumes de dados
  - Leitura distante

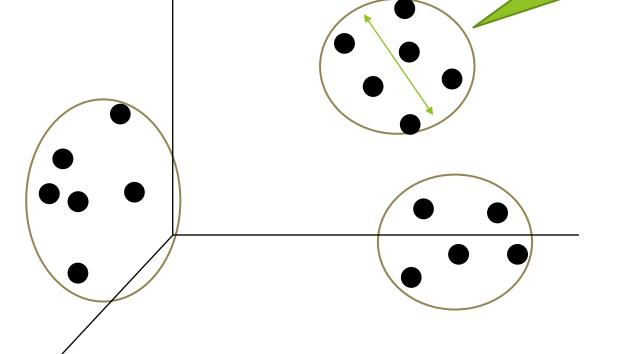
# O que é?



Idade	Peso	Altura
20	80	180
30	98	190
63	90	170
•••	•••	•••

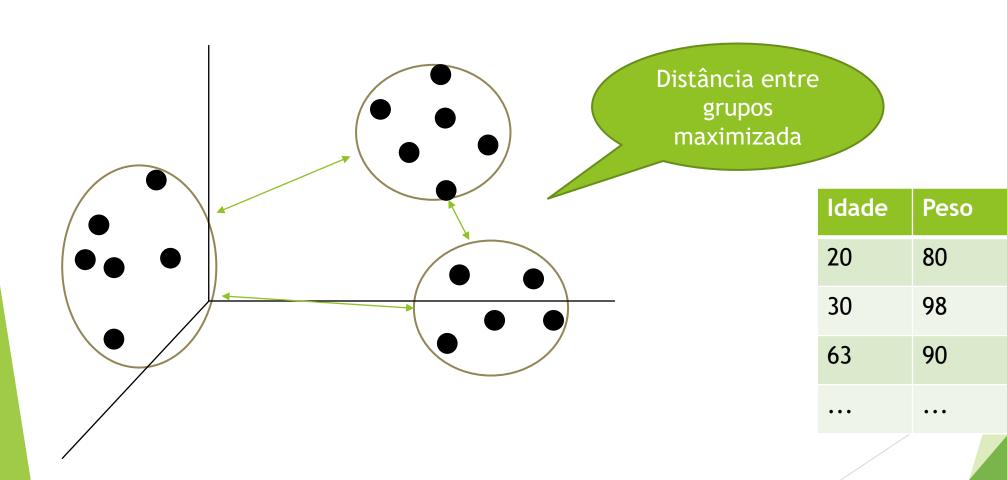
# O que é?

Distância entre membros minimizada



Idade	Peso	Altura	Grupo
20	80	180	2
30	98	190	3
63	90	170	1
•••	•••	•••	•••

# O que é?



Altura

180

190

170

Grupo

2

3

• • •

# Agrupando Moedas



► COINS — A journey through a rich cultural collection (fh-potsdam.de)

# Como agrupar documentos?



**Topic Modeling** 

T <sub>1</sub>	T <sub>2</sub>	T <sub>m</sub>
Word <sub>11</sub> , pr <sub>11</sub>	Word <sub>21</sub> , pr <sub>21</sub>	 Word <sub>m1</sub> , pr <sub>m1</sub>
Word <sub>12</sub> , pr <sub>12</sub>	Word <sub>22</sub> , pr <sub>22</sub>	 Word <sub>m2</sub> , pr <sub>m2</sub>
×	¥8	· ·
*	*	
		12.
Word <sub>1k</sub> , pr <sub>1k</sub>	Word <sub>2k</sub> , pr <sub>2k</sub>	 Word pr

**Document Clustering** 

C <sub>1</sub>	C <sub>2</sub>	•••	C <sub>m</sub>
D <sub>a</sub>	D <sub>i</sub>	***	Da
D <sub>a</sub>	D <sub>i</sub>		D <sub>a</sub>
*	*		R.
*			K.
	1020	•	21
D <sub>c</sub>	Dk		D <sub>s</sub>

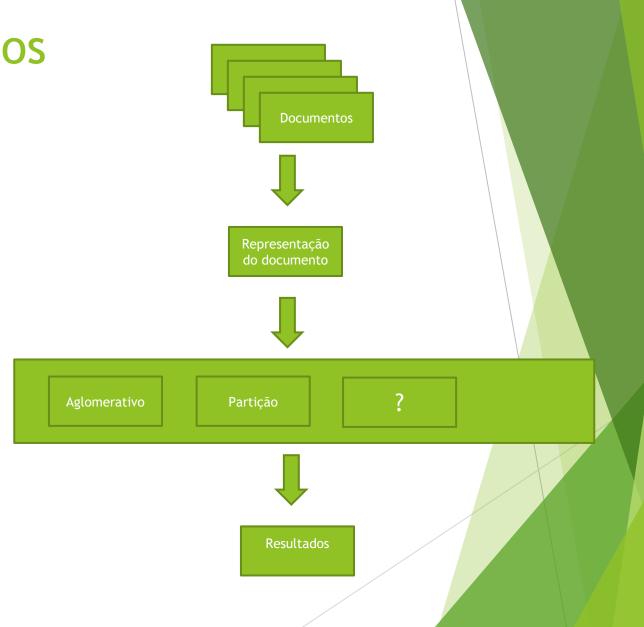
# Como agrupar documentos?

- Aparato de agrupamento
  - Estruturado
  - Numérico

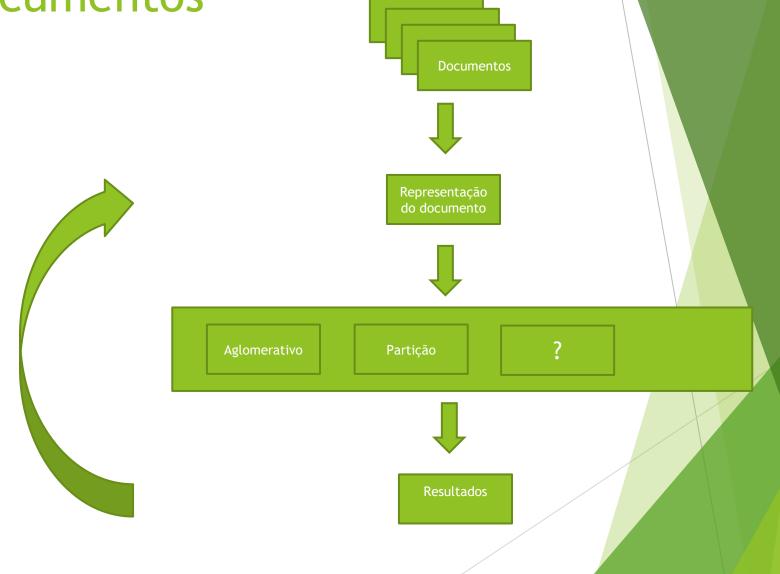
Idade	Peso	Altura	Grupo
20	80	180	2
30	98	190	3
63	90	170	1
•••	•••	•••	•••

# Agrupando Documentos

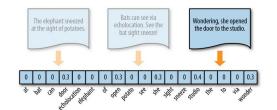
- Aparato de agrupamento
  - Estruturado
  - Numérico
- Documentos
  - ▶ Não Estruturado
  - Texto

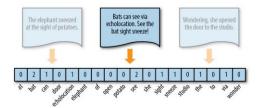


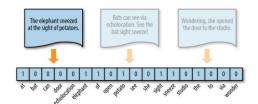
# Agrupando Documentos











# Formas de Representação

- Bag of Words
- One-Hot-Encoding
- ► TF-IDF
- Embeddings

### Tipos de Agrupamento

#### Hierárquico

- Gera uma hierarquia de subconjuntos
- Aglomerativo ou Divisivo
- Quando é útil extrair uma taxonomia

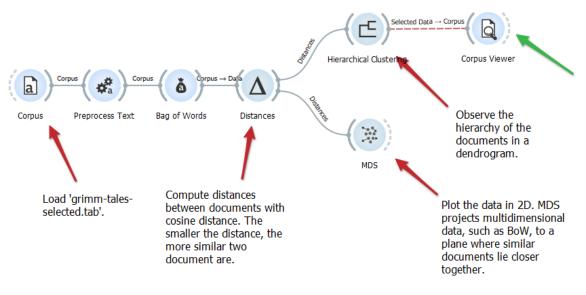
#### Partição

- Constrói k (k<n) partições</p>
- Não há hierarquia

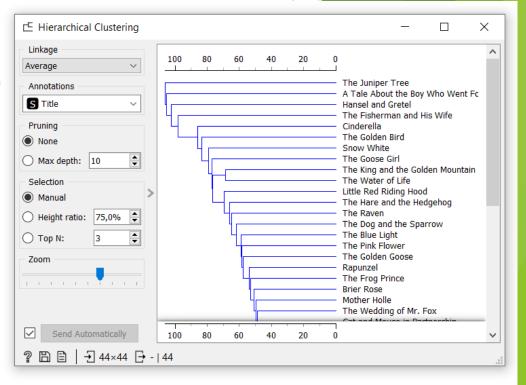
#### Densidade

- Cada ponto deve ter um número mínimo de vizinhos
- Consegue achar grupos com formas não convexas
- Útil para identificação de anomalias

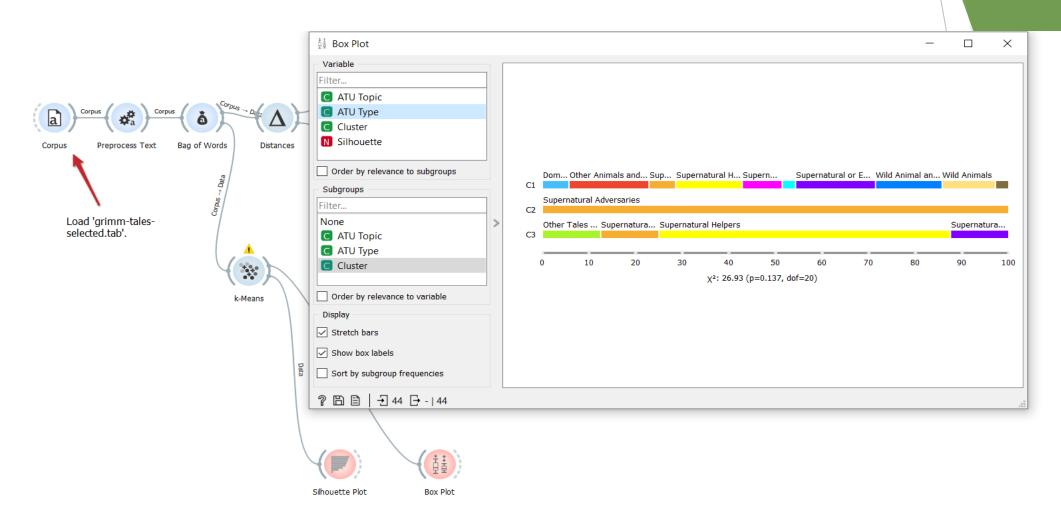
# Hierárquico



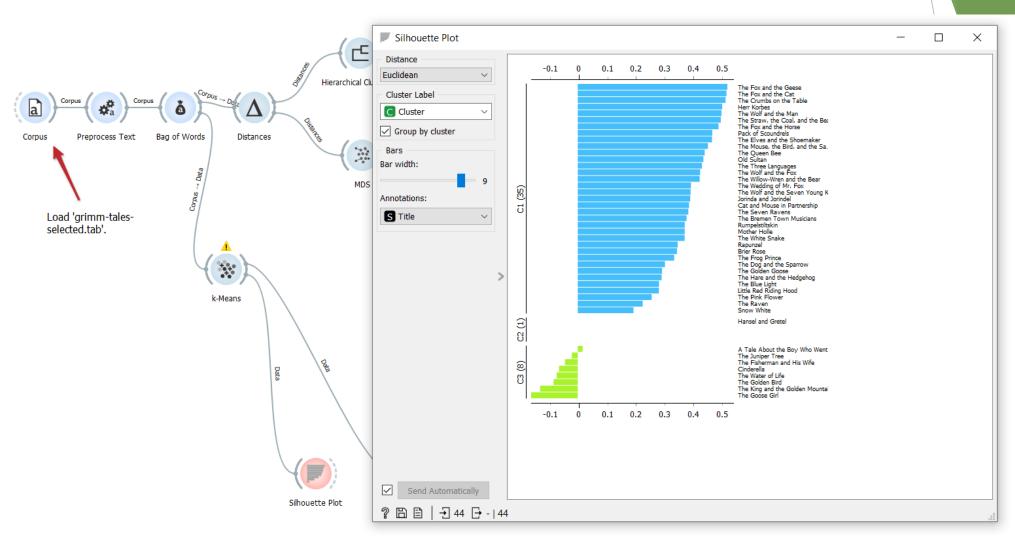
Select a cluster in Hierarchical Clustering and observe selected documents in Corpus Viewer.



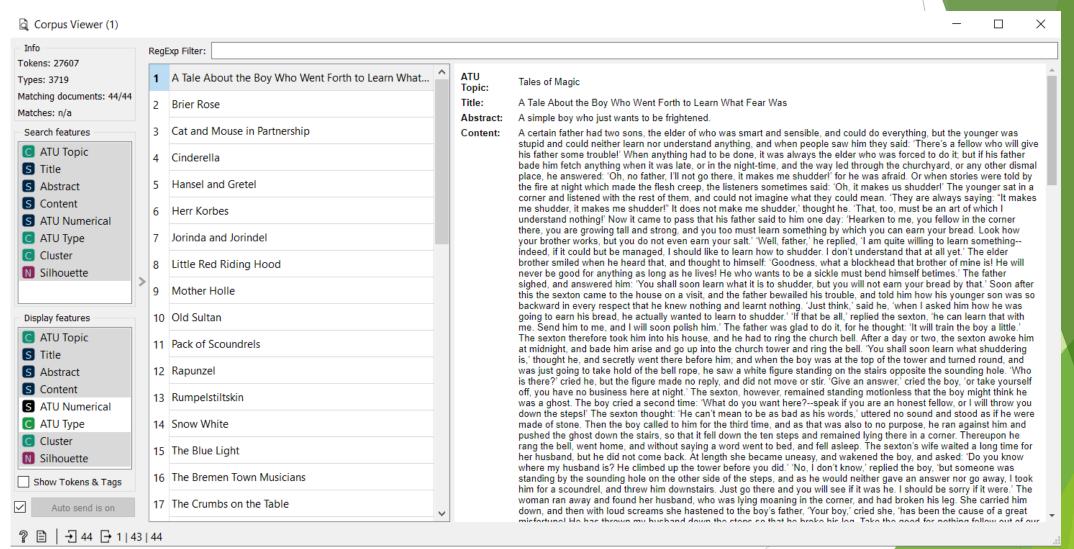
# Partição



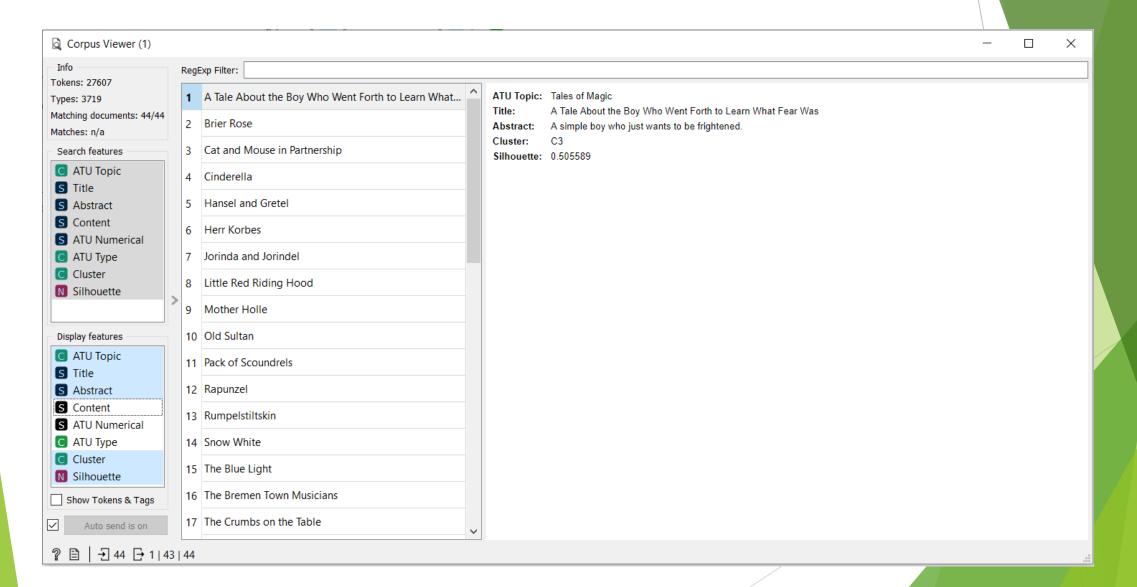
# Partição



# Análise Qualitativa



# Análise Qualitativa



### **Ferramentas**

- Orange
  - ► Provê um workflow completo e simples
- Python e Scikit
  - Exige codifição
  - Bem documentado
  - Muitos exemplos

# Considerações

- Pre processamento é importante!
  - ▶ Stemming ou lema
  - Stop words
  - Lower case
  - ...
- ► Tente mudar a representação do documento
  - ► Embeddings são muito bons e modernos

# Considerações

- Tente diferentes formas de visualização
  - Leitura distante
  - Leitura próxima
- Identifique o que você quer fazer
  - Taxonomia automática?
  - Grupos disjuntos?
  - Anomalias?
- Se o algoritmo tiver parâmetros
  - ▶ Usem algo que ajuste pela silhueta ou alguma outra função